



Actividad 1 - Análisis Exploratorio WIDS 2024



IVAN ALEJANDRO TOLEDANO JUAREZ • 23 sept (Última modificación: 28 oct)

100 puntos

En esta tarea se trabaja con los datos del reto WIDS Datathon 2024

(<https://www.kaggle.com/competitions/widsdatathon2024-challenge1>) de Kaggle, enfocado en el diagnóstico temprano de cáncer de mama y variables asociadas al estado de salud y de residencia de pacientes.

El objetivo no es construir modelos, sino realizar un análisis exploratorio estructurado que te permita comprender las variables, sus tipos, distribuciones, valores faltantes e inconsistencias. Esto será la base para preparar los datos antes de aplicar modelos de Machine Learning en la siguiente etapa.

Instrucciones:

- **Importación y revisión general**
 - Carga los datasets, muestra sus dimensiones, tipos de datos y primeras filas
 - Compara columnas entre ambos archivos train, test. ¿son idénticas? ¿falta alguna variable?
- **Revisión de valores únicos y categorías**
 - Algunas variables no comparten valores únicos entre los distintos datasets (por ejemplo, estado de residencia o código de cáncer)
 - ¿Cómo solucionarías esto?
- **Valores faltantes y anomalías**
 - Calcula el porcentaje de valores nulos por columnas
 - Identifica variables con más del 30% de valores nulos (datos de entrenamiento) y comenta si convendría eliminarlas o imputarlas
 - Observa si existen valores numéricos extremos o inconsistentes.
- **Distribución de las variables principales que identifiques**
 - Realiza visualizaciones de las variables que consideres relevantes
 - Identifica relaciones interesantes con la variable objetivo (DiagPeriod90)
- **Conclusiones y preparación para el modelado**
 - Resume los principales hallazgos que tengas
 - ¿Qué variables te parecen más útiles y por qué?
 - ¿Cuáles necesitan codificación o limpieza?
 - ¿Qué transformaciones aplicaste? (Normalización, encoding, etc.)

Entregables:

Archivos de Jupyter notebook (.ipynb) con el código y documentación de tu proceso.

NOTA: Anexo un notebook de referencia que utilicé en su momento para ir tratando los datos.



WIDS2024_Notebook...

Desconocido



Tu trabajo

Entregado

README_EDA.md

Texto



EDA.ipynb

Binario



Anular entrega

 Comentarios privados

[Añadir comentario a IVAN ALEJANDRO TOLEDANO JUAREZ](#)

 Comentarios de la clase

 [Añadir comentario](#)

